CCTV 영상 열화에 따른 교통사고 탐지 AI 의 성능 저하 및 취약성 분석

이우석
데이터사이언스학부
강남대학교
오산, 대한민국
kidde04@gmail.com

안한석
인공지능학부
강남대학교
성남, 대한민국
hanseogan@naver.com

안동현
인공지능학부
강남대학교
부천, 대한민국
bill207@naver.com

요약—(작성 예정: 6~7 줄. 배경, 문제, 방법, 평가, 기대 결과 순으로 서론과 본론을 마친 뒤 작성)

키워드—교통사고 탐지, CCTV, 영상 열화, 비전-언어 모델, 강건성 평가

I. 서론

교통사고는 전 세계에서 매년 약 119 만 명의 사망자를 발생시키는 심각한 사회 문제로, 사고를 신속하게 파악하는 기술은 지능형 교통 시스템의 핵심 요소로 주목받고 있다[1]. 최근에는 도로에 설치된 CCTV 영상에 비전-언어 모델(Vision-Language Model, VLM)을 적용하여, 별도의 학습 없이 사고의 발생 시점과 위치까지 판단하려는 연구가 진행되고 있다[2]. 그러나 실제 CCTV 영상은 원거리 촬영, 저장과 전송을 위한 압축, 차량의 움직임에 따른 모션 블러 등으로 화질이 낮은 경우가 많으며, 공개 CCTV 사고 영상으로 구성된 ACCIDENT 데이터셋에서도 영상의 약 3 분의 2 가 저화질로 분류되었다[2], [3]. 영상 열화가 AI 성능에 미치는 영향은 주로 객체 탐지를 중심으로 연구되어 왔으며[3]–[5], 여러 프레임의 변화를 읽어야 하는 사고 시점·위치 판단에서의 영향은 아직 충분히 알려져 있지 않다.

이에 본 연구는 ACCIDENT 벤치마크[2]의 실제 CCTV 사고 영상에 해상도 저하, H.264 압축, 모션 블러를 단계적으로 적용하고, Molmo-7B-D[6]의 사고 시점·위치 판단 성능이 열화에 따라 어떻게 달라지는지 원본 대비 상대 하락률로 비교·분석한다. 이를 통해 어떤 판단 능력이 어떤 열화에 더 취약한지 확인하고, CCTV 기반 사고 탐지 시스템의 화질 관리 방향을 제시하고자 한다.

II. 관련연구

A. CCTV 교통사고 벤치마크와 비전-언어 모델

ACCIDENT[2]는 실제 도로 CCTV 에서 수집한 사고 영상 2,027 개와 합성 영상 2,211 개로 구성된 벤치마크로, 사고의 발생 시점(When), 위치(Where), 유형(What)을 판단하는 세 가지 과제를 정의하였다. 각 과제의 정답은 여러 주석자의 표시를 평균하여 정하고, 예측은 정답과의 차이가 클수록 점수가 부드럽게 감소하는 가우시안 유사도로 평가한다. 별도의 학습 없이 사용한 VLM 중에서는 Molmo-7B-D 가 시점 0.343, 위치 0.596 으로 가장 높은 성능을 보였다[2]. Molmo[6]는 이미지 속 대상을 좌표로 가리키는(pointing) 데이터로 학습된 공개 VLM 으로, 본 연구에서도 별도의 학습 없이 사고 시점과 위치 판단에 사용한다.

B. 영상 열화와 AI 성능

영상 열화가 AI 성능에 미치는 영향은 주로 객체 탐지를 대상으로 분석되어 왔다. O'Byrne 등[3]은 실제 감시 영상을 H.264 코덱의 CRF(Constant Rate Factor) 22~47 로 압축하여 객체 탐지 성능을 측정하였고, CRF 42 이상에서 성능이 뚜렷하게 낮아짐을 보였다. Cai 등[4]은 모션 블러를 포함한 여러 악조건에서 차량 탐지 모델의 강건성을 평가하면서 원본 대비 성능 손실률을 지표로 사용하였으며, 윤영두·김호[5]는 해상도 축소와 압축을 함께 적용하여 탐지 신뢰도가 비선형적으로 저하되는 구간을 분석하였다. Poyser 등[7]은 행동 인식에서 프레임 간 움직임 정보가 외형 정보보다 압축에 더 민감함을 보고하여, 열화의 영향이 판단에 필요한 정보의 종류에 따라 달라질 수 있음을 보여주었다.

모션 블러는 카메라의 노출 시간 동안 피사체가 이동한 거리만큼 상이 번지는 현상이다. 따라서 블러 길이 L(픽셀)은 차량 속도와 노출 시간, 카메라의 공간 해상도로부터 다음과 같이 근사할 수 있다.

$$L = v \cdot t_e / d \tag{1}$$

여기서 v 는 차량 속도(m/s), t_e 는 노출 시간(s), d 는 픽셀 하나가 나타내는 도로 위의 실제 거리(m)이다. 본 연구는 식 (1)을 이용하여 실제 차량 속도에 대응하는 모션 블러 단계를 정한다.

III. 연구 방법

본 연구의 전체 분석 절차는 그림 1 과 같다. 실제 CCTV 사고 영상에 열화를 적용하고, 각 조건에서 Molmo-7B-D 의 사고 시점·위치 판단 성능을 측정한 뒤 원본 대비 하락률로 비교한다.

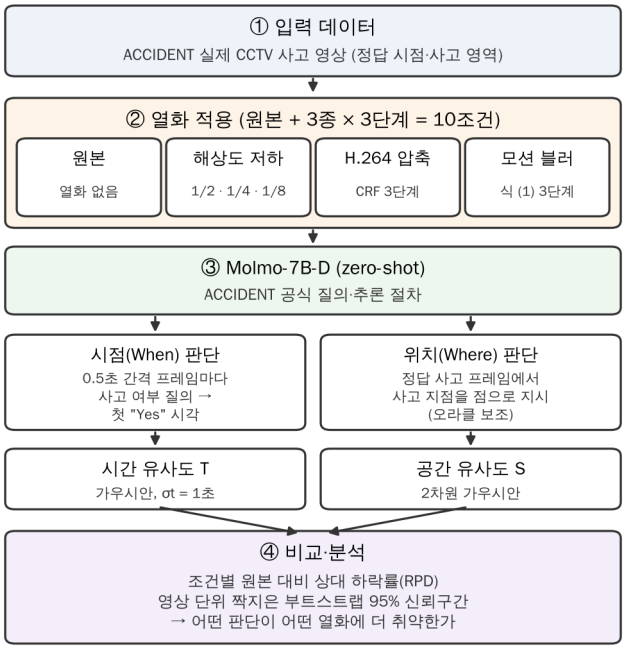


Fig. 1. 전체 분석 절차

A. *데이터셋과 모델*

실험에는 ACCIDENT 의 실제 CCTV 사고 영상 N 개(영상 수 확정 후 기입)를 사용한다. 모델은 Molmo-7B-D(allenai/Molmo-7B-D-0924)를 별도의 학습 없이 사용하며, 질의 문장과 추론 절차는 ACCIDENT 공식 코드를 따른다. 시점 판단에서는 영상을 0.5 초 간격 프레임으로 나누어 각 프레임에 사고 여부를 묻고, 처음으로 사고라고 답한 프레임의 시각을 예측 시점으로 한다. 위치 판단에서는 정답 사고 프레임 한 장을 주고 사고 지점을 점으로 가리키게 한다 위치 판단에 정답 프레임을 주는 오라클 보조 방식[2]은 시점 판단의 오류가 위치 점수에 섞이지 않도록 하기 위함이다.

B. *열화 조건*

열화는 카메라 촬영과 영상 전송 과정에서 발생하며 통제하여 재현할 수 있는 해상도 저하, H.264 압축, 모션 블러의 세 가지로 하고, 각각 3 단계를 적용한다(표 I). 해상도 저하는 프레임을 축소한 뒤 원래 크기로 다시 확대하고, 압축은 ffmpeg 의 libx264 로 영상을 재인코딩하며, 모션 블러는 식 (1)로 구한 길이의 수평 선형 커널을 각 프레임에 적용한다. 원본을 포함한 10 개 조건에서 같은 영상을 평가한다.

TABLE I. 열화 조건과 단계

열화 (단위)	1 단계	2 단계	3 단계	근거
해상도 저하 (축소 배율)	1/2	1/4	1/8	[5]
H.264 압축 (CRF)	37	42	47	[3]
모션 블러 (길이, px)	6	11	17	식 (1)

모션 블러: 차량 속도 30·60·90 km/h, 노출 시간 1/30 s, 픽셀당 거리 0.05 m 가정. 노란색 수치는 잠정값

C. *평가 지표*

시점과 위치 판단은 ACCIDENT 의 평가 방식[2]에 따라 가우시안 유사도로 측정하고, 열화의 영향은 원본 대비 상대 하락률(Relative Performance Drop, RPD)로 비교한다(표 II). RPD 는 원본 성능이 서로 다른 두 판단 능력을 같은 기준에서 비교하기 위한 것으로, 강건성 평가 연구[4]의 성능 손실률과 같은 형태이다. 조건 간 차이는 같은 영상의 원본·열화 결과를 짝지은 부트스트랩으로 95% 신뢰구간을 구하여 확인한다.

TABLE II. 평가 지표

과제	지표	정의
시점	시간 유사도 T	$\exp(-(\hat{t}-t^*)^2 / 2\sigma_t^2)$, $\sigma_t = 1$ s
위치	공간 유사도 S	$\exp(-(\hat{x}-x^*)^2 / 2\sigma_x^2 - (\hat{y}-y^*)^2 / 2\sigma_y^2)$
비교	상대 하락률 RPD	$(P_{\text{원본}} - P_{\text{열화}}) / P_{\text{원본}} \times 100$ (%)

t^*, (x^*, y^*): 정답 사고 시점과 위치, σ_x, σ_y: 사고 영역의 평균 너비·높이 (정규화 좌표)

IV. 실험 결과

(작성 예정: 원본 성능 재현, 열화별·판단 능력별 상대 하락률 비교)

V. 결론

(작성 예정: 주요 결과, 한계, 후속 연구)

참고문헌

[1] World Health Organization, Global Status Report on Road Safety 2023. Geneva, Switzerland: World Health Organization, 2023. ISBN: 978-92-4-008651-7.

[2] L. Picek, M. Čermák, M. Hanzl, and V. Čermák, "ACCIDENT: A benchmark dataset for vehicle accident detection from traffic surveillance videos," 2026, arXiv:2604.09819. [Online]. Available: https://arxiv.org/abs/2604.09819

[3] M. O'Byrne, M. Sugrue, Vibhoothi, and A. Kokaram, "Impact of video compression on the performance of object detection systems for surveillance applications," in Proc. 19th IEEE Int. Conf. Advanced Video and Signal Based Surveillance (AVSS), 2022.

[4] J. Cai, Y. Gao, and J. Tang, "Robustness benchmark evaluation and optimization for real-time vehicle detection under multiple adverse conditions," Appl. Sci., vol. 15, no. 9, Art. no. 4950, 2025.

[5] 윤영두, 김호, "영상 데이터 감쇄에 따른 보행자·차량 객체 탐지 AI 신뢰도의 비선형적 성능 저하 메커니즘과 정량적 변곡점 규명: COCO 데이터 세트 기반 YOLOv8 사례연구," 한국콘텐츠학회논문지, 제 26 권, 제 8 호, pp. 71–85, 2026. doi: 10.5392/JKCA.2026.26.08.071

[6] M. Deitke et al., "Molmo and PixMo: Open weights and open data for state-of-the-art vision-language models," in Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), 2025, pp. 91–104.

[7] M. Poyser, A. Atapour-Abarghouei, and T. P. Breckon, "On the impact of lossy image and video compression on the performance of deep convolutional neural network architectures," in Proc. 25th Int. Conf. Pattern Recognition (ICPR), 2021, pp. 2830–2837.