# CCTV 영상 열화에 따른 교통사고 탐지 AI 의 성능 저하 및 취약성 분석

이우석, 안한석*, 안동현*
강남대학교 데이터사이언스학부, *강남대학교 인공지능학부
kidde04@gmail.com, *hanseogan@naver.com, *bill207@naver.com

# Analysis of Performance Degradation and Vulnerability of Traffic Accident Detection AI under CCTV Video Degradation

Woo-Seok Lee, Han-Seok Ahn*, Dong-Hyun Ahn*
Dept. of Data Science, Kangnam Univ., *Dept. of Artificial Intelligence, Kangnam Univ.

## 요 약

본 논문은 CCTV 영상의 화질 저하가 비전-언어 모델(Vision-Language Model, VLM)의 교통사고 판단 능력에 미치는 영향을 분석한다. 실제 CCTV 사고 영상으로 구성된 ACCIDENT 벤치마크에 해상도 저하, H.264 압축, 모션 블러를 각각 3 단계로 적용하고, Molmo-7B-D 를 별도의 학습 없이 사용하여 사고의 발생 시점과 위치를 판단하는 성능을 측정한다. 각 조건의 성능은 원본 대비 상대 하락률로 비교하여 어떤 판단 능력이 어떤 열화에 더 취약한지 확인한다. 원본 영상 20 개에 대한 실험에서 시점 0.465, 위치 0.670 으로 기존 보고 수준의 성능을 재현하였다. (열화 조건별 주요 결과 1 문장 추가 예정)

## I. 서 론

교통사고는 전 세계에서 매년 약 119 만 명의 사망자를 발생시키는 심각한 사회 문제로, 사고를 신속하게 파악하는 기술은 지능형 교통 시스템의 핵심 요소로 주목받고 있다[1]. 최근에는 도로에 설치된 CCTV 영상에 VLM 을 적용하여, 별도의 학습 없이 사고의 발생 시점과 위치까지 판단하려는 연구가 진행되고 있다[2]. 그러나 실제 CCTV 영상은 원거리 촬영, 저장과 전송을 위한 압축, 차량의 움직임에 따른 모션 블러 등으로 화질이 낮은 경우가 많으며, 공개 CCTV 사고 영상으로 구성된 ACCIDENT 데이터셋에서도 영상의 약 3 분의 2 가 저화질로 분류되었다[2][3]. 영상 열화가 AI 성능에 미치는 영향은 주로 객체 탐지를 중심으로 연구되어 왔으며[3][4][5], 여러 프레임의 변화를 읽어야 하는 사고 시점·위치 판단에서의 영향은 아직 충분히 알려져 있지 않다.

이에 본 연구는 ACCIDENT 벤치마크[2]의 실제 CCTV 사고 영상에 해상도 저하, H.264 압축, 모션 블러를 단계적으로 적용하고, Molmo-7B-D[6]의 사고 시점·위치 판단 성능이 열화에 따라 어떻게 달라지는지 원본 대비 상대 하락률로 비교·분석한다. 이를 통해 어떤 판단 능력이 어떤 열화에 더 취약한지 확인하고, CCTV 기반 사고 탐지 시스템의 화질 관리 방향을 제시하고자 한다.

## II. 관련연구

### 2.1 CCTV 교통사고 벤치마크와 비전-언어 모델

ACCIDENT[2]는 실제 도로 CCTV 에서 수집한 사고 영상 2,027 개와 합성 영상 2,211 개로 구성된 벤치마크로, 사고의 발생 시점(When), 위치(Where), 유형(What)을 판단하는 세 가지 과제를 정의하였다. 각 과제의 정답은 여러 주석자의 표시를 평균하여 정하고, 예측은 정답과의 차이가 클수록 점수가 부드럽게 감소하는 가우시안 유사도로 평가한다. 별도의 학습 없이 사용한 VLM 중에서는 Molmo-7B-D 가 시점 0.343, 위치 0.596 으로 가장 높은 성능을 보였다[2]. Molmo[6]는 이미지 속 대상을 좌표로 가리키는(pointing) 데이터로 학습된 공개 VLM 으로, 본 연구에서도 별도의 학습 없이 사고 시점과 위치 판단에 사용한다.

### 2.2 영상 열화와 AI 성능

영상 열화가 AI 성능에 미치는 영향은 주로 객체 탐지를 대상으로 분석되어 왔다. O'Byrne 등[3]은 실제 감시 영상을 H.264 코덱의 CRF(Constant Rate Factor) 22~47 로 압축하여 객체 탐지 성능을 측정하였고, CRF 42 이상에서 성능이 뚜렷하게 낮아짐을 보였다. Cai 등[4]은 모션 블러를 포함한 여러 악조건에서 차량 탐지 모델의 강건성을 평가하면서 원본 대비 성능 손실률을 지표로 사용하였으며, 윤영두·김호[5]는 해상도 축소와 압축을 함께 적용하여 탐지 신뢰도가 비선형적으로 저하되는 구간을 분석하였다. Poyser 등[7]은 행동 인식에서 압축이 강해질 때 프레임 간 움직임 정보를 사용하는 경로의 성능이 외형 정보를 사용하는 경로보다 크게 떨어짐을 보고하여, 열화의 영향이 판단에 필요한 정보의 종류에 따라 달라질 수 있음을 보여주었다.

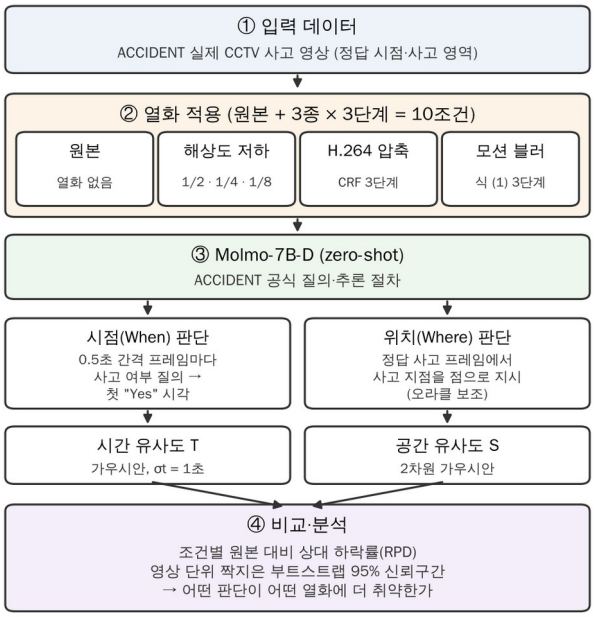
모션 블러는 카메라의 노출 시간 동안 피사체가 이동한 거리만큼 상이 번지는 현상이다. 따라서 블러 길이 $L$(픽셀)은 차량 속도와 노출 시간, 카메라의 공간 해상도로부터 식 (1)과 같이 근사할 수 있다.

$$L = v \cdot te / d \tag{1}$$

여기서 $v$ 는 차량 속도(m/s), $te$ 는 노출 시간(s), $d$ 는 픽셀 하나가 나타내는 도로 위의 실제 거리(m)이다. 본 연구는 식 (1)을 이용하여 실제 차량 속도에 대응하는 모션 블러 단계를 정한다.

## III. 연구 방법

본 연구의 전체 분석 절차는 그림 1 과 같다. 실제 CCTV 사고 영상에 열화를 적용하고, 각 조건에서 Molmo-7B-D 의 사고 시점·위치 판단 성능을 측정한 뒤 원본 대비 하락률로 비교한다.




(그림 1) 전체 분석 절차

### 3.1 데이터셋과 모델

실험에는 ACCIDENT 의 실제 CCTV 사고 영상 중 무작위로 추출한 50 개를 사용한다. 모델은 Molmo-7B-D (allenai/Molmo-7B-D-0924)를 별도의 학습 없이 사용하며, 질의 문장과 추론 절차는 ACCIDENT 공식 코드를 따른다. 시점 판단에서는 영상을 0.5 초 간격 프레임으로 나누어 각 프레임에 사고 여부를 묻고, 처음으로 사고라고 답한 프레임의 시각을 예측 시점으로 한다. 위치 판단에서는 정답 사고 프레임 한 장을 주고 사고 지점을 점으로 가리키게 한다. 위치 판단에 정답 프레임을 주는 오라클 보조 방식[2]은 시점 판단의 오류가 위치 점수에 섞이지 않도록 하기 위함이다.

### 3.2 열화 조건

열화는 카메라 촬영과 영상 전송 과정에서 발생하며 통제하여 재현할 수 있는 해상도 저하, H.264 압축, 모션 블러의 세 가지로 하고, 각각 3 단계를 적용한다(표 1). 해상도 저하는 프레임을 축소한 뒤 원래 크기로 다시 확대하고, 압축은 ffmpeg 의 libx264 로 영상을 재인코딩하며, 모션 블러는 식 (1)로 구한 길이의 수평 선형 커널을 각 프레임에 적용한다. 모션 블러 단계는 차량 속도 30·60·90 km/h, 노출 시간 1/30 s, 픽셀당 거리 0.05 m 를 가정하여 정하였다. 원본을 포함한 10 개 조건에서 같은 영상을 평가한다.

(표 1) 열화 조건과 단계

| 열화 (단위) | 1 단계 | 2 단계 | 3 단계 | 근거 |
|---|---|---|---|---|
| 해상도 저하 (축소 배율) | 1/2 | 1/4 | 1/8 | [5] |
| H.264 압축 (CRF) | 37 | 42 | 47 | [3] |
| 모션 블러 (길이, px) | 6 | 11 | 17 | 식 (1) |

### 3.3 평가 지표

시점과 위치 판단은 ACCIDENT 의 평가 방식[2]에 따라 가우시안 유사도로 측정하고, 열화의 영향은 원본 대비 상대 하락률(Relative Performance Drop, RPD)로 비교한다(표 2). RPD 는 원본 성능이 서로 다른 두 판단 능력을 같은 기준에서 비교하기 위한 것으로, 강건성 평가 연구[4]의 성능 손실률과 같은 형태이다. 조건 간 차이는 같은 영상의 원본·열화 결과를 짝지은 부트스트랩으로 95% 신뢰구간을 구하여 확인한다.

(표 2) 평가 지표

| 과제 | 지표 | 정의 |
|---|---|---|
| 시점 | 시간 유사도 $T$ | $\exp(-(\hat{t}-t^{*})^2 / 2\sigma t^2)$, $\sigma t = 1$ s |
| 위치 | 공간 유사도 $S$ | $\exp(-\Delta x^2 / 2\sigma x^2 - \Delta y^2 / 2\sigma y^2)$ |
| 비교 | 상대 하락률 RPD | ($P$ 원본 − $P$ 열화) / $P$ 원본 × 100 (%) |

## IV. 실험 결과

### 4.1 원본 성능 재현

열화를 적용하기 전에 원본 영상에서 성능을 확인하였다(표 3). 무작위로 추출한 영상 20 개에서 Molmo-7B-D 는 시점 0.465, 위치 0.670 으로 단순 기준선(영상 중앙 시각, 화면 중앙 좌표)보다 크게 높았으며, ACCIDENT 에서 보고된 값과 비슷한 수준이었다. 영상별 점수가 0 또는 1 에 가깝게 나뉘는 경향이 있어 표본이 작을 때 평균이 보고값과 차이를 보일 수 있다. 시점 판단에서 사고를 한 번도 탐지하지 못한 영상은 10%였다.

(표 3) 원본 영상에서의 성능

| 구분 | 영상 수 | 시점 $T$ | 위치 $S$ |
|---|---|---|---|
| 단순 기준선[2] | 2,027 | 0.190 | 0.250 |
| Molmo-7B-D 보고값[2] | 2,027 | 0.343 | 0.596 |
| Molmo-7B-D 재현 (본 연구) | 20 | 0.465 | 0.670 |

### 4.2 열화 조건별 성능 비교

(작성 예정) 영상 50 개로 10 개 조건을 실행한 뒤, 표 4 의 조건별 점수와 하락률, 열화 단계에 따른 성능 변화 그래프(그림 2)를 바탕으로 어떤 판단 능력이 어떤 열화에 더 취약한지 서술한다.

(표 4) 열화 조건별 성능과 원본 대비 하락률

| 조건 | *T* | RPDT (%) | *S* | RPDS (%) |
|---|---|---|---|---|
| 원본 | – | – | – | – |
| 해상도 1/2 · 1/4 · 1/8 | – | – | – | – |
| H.264 CRF 37 · 42 · 47 | – | – | – | – |
| 모션 블러 6 · 11 · 17 px | – | – | – | – |

## V. 결 론

본 논문은 실제 CCTV 사고 영상에 해상도 저하, H.264 압축, 모션 블러를 단계적으로 적용하여, VLM 의 사고 시점·위치 판단 성능이 열화에 따라 어떻게 저하되는지 분석하는 평가 체계를 제시하였다. 원본 영상에서는 기존 보고 수준의 성능을 재현하였으며, (열화 결과: 어떤 판단이 어떤 열화에 가장 취약한지 1~2 문장). 이는 CCTV 기반 사고 탐지 시스템에서 관리해야 할 화질 조건을 판단 능력별로 제시한다는 점에서 의미가 있다. 다만 본 연구는 하나의 모델과 제한된 수의 영상을 사용하였고, 열화를 합성으로 재현하였다는 한계가 있다. 향후에는 다른 VLM 과 더 많은 영상으로 분석을 확장하고, 열화에 강건한 학습 및 복원 기법과 합성 데이터를 활용한 학습 방향을 연구할 계획이다.

## 참 고 문 헌

[1] World Health Organization, “Global Status Report on Road Safety 2023”, World Health Organization, Geneva, 2023.

[2] L. Picek, M. Čermák, M. Hanzl, V. Čermák, “ACCIDENT: A Benchmark Dataset for Vehicle Accident Detection from Traffic Surveillance Videos”, Proc. of IEEE/CVF Conf. on Computer Vision and Pattern Recognition Workshops (CVPRW), 2026.

[3] M. O’Byrne, M. Sugrue, Vibhoothi, A. Kokaram, “Impact of Video Compression on the Performance of Object Detection Systems for Surveillance Applications”, Proc. of IEEE Int. Conf. on Advanced Video and Signal Based Surveillance (AVSS), 2022.

[4] J. Cai, Y. Gao, J. Tang, “Robustness Benchmark Evaluation and Optimization for Real-Time Vehicle Detection under Multiple Adverse Conditions”, Applied Sciences, Vol. 15, No. 9, 4950, 2025.

[5] 윤영두, 김호, “영상 데이터 감쇄에 따른 보행자·차량 객체 탐지 AI 신뢰도의 비선형적 성능 저하 메커니즘과 정량적 변곡점 규명: COCO 데이터 세트 기반 YOLOv8 사례연구″, 한국콘텐츠학회논문지, 제 26 권, 제 8 호, pp. 71-85, 2026.

[6] M. Deitke et al., “Molmo and PixMo: Open Weights and Open Data for State-of-the-Art Vision-Language Models”, Proc. of IEEE/CVF Conf. on Computer Vision and Pattern Recognition (CVPR), pp. 91-104, 2025.

[7] M. Poyser, A. Atapour-Abarghouei, T. P. Breckon, “On the Impact of Lossy Image and Video Compression on the Performance of Deep Convolutional Neural Network Architectures”, Proc. of 25th Int. Conf. on Pattern Recognition (ICPR 2020), pp. 2830-2837, 2021.